

# 基于量化多因子的行业配置策略之三： 机器学习算法下的行业轮动

## ——行业轮动专题报告

投资咨询业务资格：  
证监许可【2012】669号

### 报告要点

本文在专题报告《行业轮动系列专题四：基于量化多因子的行业配置策略之二：风险控制进阶、动量加速度和因子参数的秘密》的基础上，对中高需求下的行业轮动的量化解决方案进行了改进。本文中的改进主要在于引入了机器学习中的回归算法。在回测期内，XGBoost 和 SVM 算法对策略有加成，但 Weighted KNN 算法整体效果不佳。

### 摘要：

**机器学习与行业轮动：**行业轮动的截面模型对行业收益率的预测是一个具体数值，且有监督学习，符合机器学习回归算法中“标注的数据集具有数值型的目标变量”的特点，可以考虑引入该算法。


**引入 XGBoost 算法的行业轮动：**策略相对于原策略有提升。XGBoost 算法可以进一步挖掘残差中的非线性信息，全回测期内年化收益率提升至 **31.24%**，夏普 **1.41**。同时最大回撤降低，但年化波动率有扩大。

**引入 SVM 算法的行业轮动：**策略取得了和 XGBoost 算法相似的效果，但提升不如 XGBoost 算法多，回测期内收益率和最大回撤较原策略更优，分别为 **30.99%** 和 **16.21%**，波动率仍扩大，夏普 **1.42**。

**引入 Weighted KNN 算法的行业轮动：**Weighted KNN 算法在理论上比较明显的缺陷：训练集大时预测效率低、样本少的区域容易过拟合、预测曲线不连续等。此算法下，收益率、波动率、最大回撤均比原策略更差。

**策略总结：**XGBoost 和 SVM 算法效果接近，两者都要远优于 Weighted KNN

**风险因素：**模型/方法失效、回测数据时间长度不够、指数数量较少、没有考虑交易成本。



### 量价策略团队

研究员：  
张革  
021-60812988  
zhangge@citicsf.com  
从业资格号 F3004355  
投资咨询号 Z0010982

## 目 录

摘要：	1
一、 机器学习算法与行业轮动	3
(一) 经典机器学习的三大方向	3
(二) 行业轮动中的机器学习算法引入	3
二、 引入机器学习算法的行业轮动策略：XGBoost	5
(一) XGBoost 算法简述	5
(二) 策略回测和业绩表现：引入 XGBoost 的行业轮动策略	6
三、 引入机器学习算法的行业轮动策略：SVM	7
(一) SVM 算法简述	7
(二) 策略回测和业绩表现：引入 SVM 的行业轮动策略	8
四、 引入机器学习算法的行业轮动策略：Weighted KNN	9
(一) Weighted KNN 算法简述	9
(二) 策略回测和业绩表现：引入 Weighted KNN 的行业轮动策略	10
五、 策略总结和风险提示	11
(一) 策略总结：全策略回顾	11
(二) 策略风险提示	12
(三) 后续改进方案	12
附录：部分指数一览	13
免责声明	15

## 图目录

图表 1：	机器学习算法的三大方向以及与行业轮动的关系	4
图表 2：	基策略因子组合	4
图表 3：	净值曲线：引入 XGBoost 的行业轮动策略	6
图表 4：	业绩指标：引入 XGBoost 的行业轮动策略 vs 基策略	7
图表 5：	支持向量机 VS 支持向量回归	8
图表 6：	净值曲线：引入 SVM 的行业轮动策略	8
图表 7：	业绩指标：引入 SVM 的行业轮动策略 vs 基策略	9
图表 8：	净值曲线：引入 Weighted KNN 的行业轮动策略	10
图表 9：	业绩指标：引入 Weighted KNN 的行业轮动策略 vs 基策略	10
图表 10：	引入机器学习算法策略的业绩指标：全策略回顾	11
图表 11：	部分指数一览	13

## 一、机器学习算法与行业轮动

### （一）经典机器学习的三大方向

机器学习算法是由普通算法演化而来的。通过自动地从提供的数据中学习，它会让我们的程序变得更“聪明”。机器学习利用统计技术提供了向计算机“学习”数据的能力，而不需要复杂的编程。经典的机器学习主要有三大方向：**回归、分类和聚类**。其中，回归和分类一般属于**有监督学习**，聚类属于**无监督学习**。

对于三大方向，可以简要概括的介绍为：

- **回归算法：**回归是一种对数值型连续随机变量进行预测和建模的监督学习算法。使用案例如股票走势、资产价格预测等连续变化的案例。回归任务的特点是标注的数据集具有数值型的目标变量，回归方程的两端一般都是数值型变量，或能够转换为数值型变量的变量，如 true/false、行业变量等。回归算法每一个观察样本都有一个数值型的标注真值以监督算法。常见的回归算法如**线性回归 (正则化)**、**回归树 (集成)** 以及**最近邻算法**等；
- **分类算法：**分类方法是一种对离散型随机变量建模或预测的监督学习算法。使用案例和场景包括邮件过滤、金融欺诈和预测雇员异动等输出为类别的任务。值得注意的是，许多回归算法都有与其相对应的分类算法，分类算法通常适用于预测一个类别 (或类别的概率) 而不是连续的数值。常见的分类算法包括 **Logistic 回归 (正则化)**、**分类树 (集成方法)**、**深度学习**、**支持向量机**和**朴素贝叶斯**等；
- **聚类算法：**和回归算法与分类算法不同，聚类是一种**无监督学习**任务，该算法基于数据的内部结构寻找观察样本的自然族群 (即集群)。典型的使用案例包括细分客户、新闻聚类、文章推荐等。因为聚类是一种无监督学习 (即数据没有标注)，并且通常使用数据可视化评价结果。如果存在“正确的回答” (即在训练集中存在预标注的集群)，那么分类算法可能更加合适。常见的聚类算法包括 **K 均值聚类**、**Affinity Propagation (AP) 聚类**、**层次聚类 (Hierarchical / Agglomerative)**、**DBSCAN** 等；

### （二）行业轮动中的机器学习算法引入

机器学习算法有其不同的适配和应用场景。机器学习能够进一步挖掘传统线性模型以外的**非线性**信息，可以作为经典线性回归的补充。在本文的行业配置研究中，回归算法适配性最高，这是由于本文中截面模型对行业收益率的预测是一个具体数值，且是有监督学习 (过去的行业收益率是已知的)，符合回归算法中“标注的数据集具有数值型的目标变量”的特点。

分类算法对行业配置也具有一定程度的适配性。许多相似研究的做法是将行业粗

暴的分成两类，例如上涨行业和下跌行业，然后等权配置所有选出的上涨行业。这样的做法确实可以发挥分类器的特点，也符合大众对于投资的直观认知，且有助于消除样本外推的细节性问题，例如，有研究表现，离散化可以提升策略的鲁棒性，帮助策略消除预测噪音。本文暂未找到聚类算法在行业轮动研究中的有效应用模式，或在后续报告中进行更多介绍。

本文的后续研究将围绕机器学习算法中的回归算法来展开。本文将机器学习应用于线性回归后的残差项，以进一步捕捉模型中的非线性特征。

在专题报告《行业轮动系列专题四：基于量化多因子的行业配置策略之二：风险控制进阶、动量加速度和因子参数的秘密》中，本系列介绍了风险控制方案的升级、动量加速度因子、敏感风险因子以及换用中证 800 指数作为基准。本文首先引入这些变化，并将此模型设为基模型，然后在此基础上测试机器学习算法的效果。具体来说，本文一共测试了三种回归算法：XGBoost、SVM 和 Weighted KNN。

图表 1：机器学习算法的三大方向以及与行业轮动的关系

机器学习算法方向	回归算法	分类算法	聚类算法
概念	对数值型连续随机变量进行预测和建模	对离散型随机变量建模或预测	基于数据的内部结构寻找观察样本集群
监督	有监督学习	有监督学习	无监督学习
典型场景	股票走势、资产价格预测	邮件过滤、金融欺诈和预测雇员异动	细分客户、新闻聚类、文章推荐
与行业轮动的适配	匹配，如用于行业预期收益率的预测	比较匹配，如将行业分为上涨行业和下跌行业	暂未形成匹配和应用方案

资料来源：中信期货研究部

图表 2：基策略因子组合

风格大类	说明	因子定义
贝塔 Beta	历史贝塔	权益收益率对沪深 300 收益率的时间序列回归，取回归系数
动量 Momentum	年相对强度	计算非滞后的相对强度：对权益的对数收益率进行指数加权求和，然后计算滞后交易日的窗口内的非滞后相对强度的等权平均值
动量 Momentum	历史 Alpha	在计算贝塔所进行的时间序列回归中取回归截距项，然后计算滞后交易日的窗口内的非滞后值的等权平均值
残差波动率 Residual Volatility	历史残差波动率	在计算贝塔所进行的时间序列回归中，取回归残差收益率的波动率
残差波动率 Residual Volatility	日收益率标准差	最近一年日收益率的波动率
残差波动率 Residual Volatility	累积收益率范围	最近 12 个月累积对数收益率的最大值减去最小值

特征因子	偏度	最近一年日收益率的偏度
特征因子	峰度	最近一年日收益率的峰度
特征因子：敏感风险因子	在险价值	最近一个季度日收益率的在险价值
特征因子：敏感风险因子	期望损失	最近一个季度日收益率的期望损失
动量加速度 Momentum Acceleration	相对强度加速度	相对强度对时间的一阶导数
动量加速度 Momentum Acceleration	历史 alpha 加速度	历史 alpha 对时间的一阶导数

资料来源：中信期货研究部

## 二、引入机器学习算法的行业轮动策略：XGBoost

### （一）XGBoost 算法简述

XGBoost (eXtreme Gradient Boosting) 是大规模并行 boosting tree 的工具，被认为是目前最快最好的开源 boosting tree 算法。XGBoost 和 GBDT (Gradient Boosting Decision Tree) 都属于 Gradient Boosting, 且 XGBoost 在 GBDT 的基础上有进一步改进。因此，要了解 XGBoost, 可以先了解 GBDT。

GBDT (Gradient Boosting Decision Tree) 梯度提升迭代决策树，是 Boosting 算法的一种。GBDT 使用的弱学习器必须是 CART (Classification and Regression Trees, 分类与回归树)，且必须是回归树。GBDT 一般用来做回归预测，当然，通过设置阈值也可以用于分类任务。在模型训练时，模型预测样本损失要尽可能小。

GBDT 的一个直观理解可以是：**模型的每一轮预测都和真实值有误差，这个误差在统计上称为残差，下一轮模型继续对残差进行预测，最后将所有预测结果相加，得到最终结果。**GBDT 每一棵树学习的是前面所有树结论和的残差。同时，GBDT 也引入了 shrinkage 的思想，每棵残差树只学到了真实情况的一小部分，希望通过每次走一小步的方式逐渐逼近真实结果。GBDT 认为这样比每次迈一大步的方式更容易避免过拟合。

基于残差的 GBDT 在解决回归问题上不算好的选择，因为此算法对异常值过于敏感，不适合高维稀疏特征，也不好并行计算。XGBoost 相比 GBDT 在如下方面做了改进：

- GBDT 只将目标函数 Taylor 展开到一阶，而 XGBoost 将目标函数展开到了二阶，进而保留了更多有关目标函数的信息
- XGBoost 加入了叶子权重的 L2 正则化项，有利于模型获得更低的方差
- XGBoost 增加了自动处理缺失值特征的策略



## （二）策略回测和业绩表现：引入 XGBoost 的行业轮动策略

在专题报告《行业轮动系列专题四：基于量化多因子的行业配置策略之二：风险控制进阶、动量加速度和因子参数的秘密》的基础上，使用 2014 年开始的数据，并**对残差引入 XGBoost 算法**，本文测试了基于 Barra 风格因子+自研特征因子的多因子策略的业绩表现。在回测期内，本段加入动态仓位控制对策略权重按风险进行调整，同时限制指数直接做空。本策略无期货做空/无杠杆，每日调仓。

在回测期 (2014/01 至今) 内,引入 XGBoost 的策略相对于原策略有提升。XGBoost 算法可以进一步挖掘残差中的非线性信息，**提高全回测期内策略年化收益率，同时降低最大回撤**。与之伴随的风险是**年化波动率的扩大**。

需要注意的是，本文使用的线性模型中，因子个数和行业/主题指数个数本身差距不大，线性模型存在比较明显的过拟合现象，尤其是回测期前期。在无法扩大样本容量的情况下，此问题没有太好的办法解决，这导致残差在模型中的比重本身较低，XGBoost 算法发挥的空间不大。因此，**原策略和新策略的净值曲线是比较接近的**。如果将同样的方法用于个股，过拟合的现象会好很多，可能会更容易观察机器学习算法的效果。本团队或在后续报告中进行相应研究。

图表 3： 净值曲线：引入 XGBoost 的行业轮动策略



资料来源：同花顺 中信期货研究部

图表 4： 业绩指标：引入 XGBoost 的行业轮动策略 vs 基策略

业绩指标	引入 XGBoost	原策略	沪深 300 全收益
年化收益率	31.24%*	29.75%	13.13%
年化波动率	19.43%	19.02%*	23.37%
年化夏普比率 (3%无风险收益)	1.41*	1.36	0.42
最大回撤	16.73%*	18.44%	46.06%
卡玛比率	1.87*	1.61	0.28

\*：子项目最优

资料来源：同花顺 中信期货研究部

### 三、引入机器学习算法的行业轮动策略：SVM

#### （一）SVM 算法简述


经典的支持向量机 (Support Vector Machines, SVM) 是一种二分类模型，它的基本模型是定义在特征空间上的间隔最大的线性分类器。SVM 还包括核技巧，这使它成为实质上的非线性分类器。**SVM 的学习策略是间隔最大化**，可形式化为一个求解凸二次规划的问题，也等价于正则化的合页损失函数的最小化问题。SVM 的学习算法就是求解凸二次规划的最优化算法。

SVM 学习的基本想法是求解能够正确划分训练数据集并且几何间隔最大的分离超平面。对于线性可分的数据集来说，这样的超平面有无穷多个（即感知机），但是几何间隔最大的分离超平面却是**唯一的**。

不只是作为经典的分类器，SVM 亦可以推广至**回归器**，即 SVR (Support Vector Regression, 支持向量回归)，SVR 和 SVM 的联系是优化问题很相像：对于回归问题，给定训练数据，希望学得一个回归模型使估计值与实际值尽可能接近。对于给定样本，传统回归模型通常直接基于模型输出与真实输出之间的差别来计算损失，当且仅当两者完全一样时，损失才为 0。与此不同，**支持向量回归 (SVR) 假设我们能容许模型输出与真实输出之间最多有不超一定阈值的误差**，即仅当它们之间的差的绝对值大于阈值时才计算损失。这相当于以超平面为中心并构建一个宽度为一定阈值的间隔带，落在间隔带以内的样本不计算损失，落在间隔带以外的样本则计算。优化的目的是使这个间隔带尽可能多的包裹住样本，同时尽可能少的样本落在间隔带之外。

下图简要表示了支持向量机和支持向量回归的方法差异，其中**菱形点**为有效点。图中，支持向量机寻找的是一条**分割直线**，目的是所有点中距离直线最近的菱形点离直线的绝对距离要尽量远；支持向量回归寻找的是一个**带状区域**，目的是区域外的点尽量少，且距离边界要尽量近，同时带状区域越窄越好。

图表 5： 支持向量机 VS 支持向量回归



资料来源：中信期货研究部

## （二） 策略回测和业绩表现：引入 SVM 的行业轮动策略

使用第二章（二）的方法，本段对残差引入 SVM 算法进行测试。

在回测期（2014/01 至今）内，引入 SVM 的策略相对于原策略有提升，取得了和 XGBoost 算法相似的效果，但提升不如 XGBoost 算法多。从结果来看，SVM 算法也可以进一步挖掘残差中的非线性信息，提高全回测期内策略年化收益率，同时更多的降低了最大回撤。与之伴随的风险依然是年化波动率的扩大。

需要注意的是，本文使用的线性模型存在比较明显的过拟合现象，残差在模型中的比重本身较低，SVM 算法发挥的空间不大。这一点与前一章是一致的。

图表 6： 净值曲线：引入 SVM 的行业轮动策略



资料来源：同花顺 中信期货研究部



图表 7： 业绩指标：引入 SVM 的行业轮动策略 vs 基策略

业绩指标	引入 SVM	原策略	沪深 300 全收益
年化收益率	30.99%*	29.75%	13.13%
年化波动率	19.17%	19.02%*	23.37%
年化夏普比率 (3%无风险收益)	1.42*	1.36	0.42
最大回撤	16.21%*	18.44%	46.06%
卡玛比率	1.91*	1.61	0.28

\*：子项目最优

资料来源：同花顺 中信期货研究部

## 四、引入机器学习算法的行业轮动策略：Weighted KNN

### （一）Weighted KNN 算法简述

KNN (K Nearest Neighbors) 可以说是最简单的分类算法之一，同时，它也是最常用的分类算法之一。注意，KNN 算法是有监督学习中的分类算法，它看起来和另一个机器学习算法 K-Means 有点像，但 K-Means 是无监督学习算法，两者有本质区别。

KNN 的全称是 K Nearest Neighbors，意思是 K 个最近的邻居。顾名思义，K 近邻算法，即给定一个训练数据集，对新的输入实例，在训练数据集中找到与该实例最邻近的 K 个实例，这 K 个实例的多数属于某个类，就把该输入实例分到这个类中，比较类似于少数服从多数的思想。

相比其他算法，KNN 算法有以下优点：

- 简单易用且简洁明了，没有很高的数学基础也能搞清楚它的原理
- “懒惰学习”的代表，在训练阶段只是把数据保存下来，训练时间开销为 0
- 非参数方法，无需估计参数，在某些情况下预测效果好，且对异常值不敏感

KNN 也可以推广至回归器，其预测值是 K 个最邻近点预测值的均值。Weighted KNN (加权 KNN) 的想法就是给越相近的邻近点越大的权重。

实际应用中，KNN/Weighted KNN 算法存在比较明显的缺陷。KNN 本身对计算机内存要求较高，当训练集较大时，KNN 的预测阶段效率很低，而对于样本少的区域又容易过拟合，边界处 bias 会比较大。另外，KNN 也有预测曲线不连续的问题，这会导致预测结果与常识背离，例如，KNN 可能会预测 100 平的房屋价格与 101 平的房屋价

格差异较大，这样的结论或难以让人信服。

以上问题也导致 KNN 回归在实际应用中很少获得出场机会。本着求证的态度，本段还是测试了加权 KNN 回归在行业轮动模型中的效果。


## （二）策略回测和业绩表现：引入 Weighted KNN 的行业轮动策略

使用第二章（二）的方法，本段对残差引入 Weighted KNN 算法进行测试。

在回测期（2014/01 至今）内，引入 Weighted KNN 的策略相对于原策略整体来看未有提升，反而在很长时期内不如原策略。从结果来看，Weighted KNN 算法对残差中非线性信息的挖掘并不好，**既不能提高收益率，也无法降低波动率，最大回撤也比原策略更高。**这印证了本文之前的怀疑性猜测：**KNN 算法有比较明显的缺陷。**

需要注意的是，本文使用的线性模型存在比较明显的过拟合现象，残差在模型中的比重本身较低，Weighted KNN 算法发挥的空间不大（但效果已经较差了）。其余讨论与上一章大致相同。

图表 8：净值曲线：引入 Weighted KNN 的行业轮动策略



资料来源：同花顺 中信期货研究部

图表 9：业绩指标：引入 Weighted KNN 的行业轮动策略 vs 基策略

业绩指标	引入 Weighted KNN	原策略	沪深 300 全收益
年化收益率	27.97%	29.75%*	13.13%

年化波动率	19.31%	19.02%*	23.37%
年化夏普比率 (3%无风险收益)	1.25	1.36*	0.42
最大回撤	20.22%	18.44%*	46.06%
卡玛比率	1.38	1.61*	0.28

\*：子项目最优

资料来源：同花顺 中信期货研究部

## 五、策略总结和风险提示

### （一）策略总结：全策略回顾

本文在专题报告《行业轮动系列专题四：基于量化多因子的行业配置策略之二：风险控制进阶、动量加速度和因子参数的秘密》的基础上，引入了机器学习算法（回归器），多数策略在回测期内表现优秀。本文中所有策略均基于行业、主题和宽基指数，没有进行行业内选股，也没有叠加基本面信息。本文内容可简要总结如下：

- 引入 XGBoost 算法，可以进一步挖掘残差中的非线性信息，提高全回测期内策略年化收益率，同时降低最大回撤。与之伴随的风险是年化波动率的扩大
- 引入 SVM 算法，取得了和 XGBoost 算法相似的效果，但提升不如 XGBoost 算法多，回测期内收益率和最大回撤更优，波动率扩大
- Weighted KNN 算法对残差中非线性信息的挖掘并不好，收益率、波动率、最大回撤均比原策略更差，该算法在理论上亦有比较明显的缺陷
- 总体效果：XGBoost  $\approx$  SVM  $\gg$  Weighted KNN

图表 10：引入机器学习算法策略的业绩指标：全策略回顾

业绩指标	引入 XGBoost	引入 SVM	引入 Weighted KNN	原策略	沪深 300 全收益
年化收益率	31.24%*	30.99%	27.97%	29.75%	13.13%
年化波动率	19.43%	19.17%	19.31%	19.02%*	23.37%
年化夏普比率 (3%无风险收益)	1.41	1.42*	1.25	1.36	0.42
最大回撤	16.73%	16.21%*	20.22%	18.44%	46.06%
卡玛比率	1.87	1.91*	1.38	1.61	0.28

\*：子项目最优

资料来源：同花顺 中信期货研究部

## （二）策略风险提示

虽然组合策略回测期内表现优异，但在实际使用中，仍有一些风险点需要特别注意。这些风险点主要来自于以下层面：

- **数据时间长度比较短：**受限于指数数量以及数据长度，本文虽选择了尽量长的回测期，但时间区间依然是人为选取的，与国外成熟的研究相比回测时间仍然较短，仅 8 年左右（2014 年 1 月至今，约 1900 个交易日）。因此，策略表现较好也可能时受到时间区间影响的结果，在更长的时间段内能否仍然表现较好需审慎评估
- **线性模型过拟合比较严重：**由于指数数量本身较少（开始阶段大约只有 20 个指数），模型前期过拟合现象比较严重，策略在标的较少时超额收益不明显，叠加牛市行情甚至没有超额收益；后期随着指数数量的上升以及单边市场的改善，策略超额收益逐渐增加。此外，过拟合导致线性模型的残差部分占比较少，机器学习算法能发挥的空间不大，可能无法非常客观的反应机器学习算法的能力
- **没有考虑交易成本：**本文使用指数进行回测，其对应的场内 ETF 通常交易成本较低，加上本文中的策略是一个日频策略，非日内高频，因此本文在回测时没有考虑任何交易费用和冲击成本。考虑交易成本后，实际情况下策略净值会略低于本文中的业绩表现。另外，自 2021 年 7 月 19 日起，沪深交易所同步降低基金（包括封闭式基金、ETF、LOF）竞价交易经手费，场内 ETF 交易成本有较大降低
- **算法对可能对参数较为敏感：**由于机器学习算法参数较多，本文只测试了默认或常见参数；对于非默认或常见情况，可能带来策略的波动和冲击

## （三）后续改进方案

为解决以上不足，有以下方案可以作为后续改进的参考：

- **考虑将相似的方法应用于个股层面，而不是行业层面：**与行业/主题指数相比，个股的数量较多，产生过拟合的几率低，可以留下充分的空间给机器学习算法发挥，或能更好的评估策略的实战能力
- **考虑对算法进行调参和进行策略的多参数组合：**最优模型对应的参数在样本外的泛化能力或有限，通过对策略进行多参数组合，可以提高模型外推的能力，在实证下也被证明可以降低策略的波动率，通常也伴随更优夏普比
- **考虑在回测时加入交易成本和冲击成本**

## 附录：部分指数一览

本文使用了**行业**和**宽基指数**作为测算数据，基于指数的规模和流动性，指数**同时**满足：

- 有对应的 ETF，且为股票型母基金
- 对应的 ETF 流动性良好，日成交额在 5000 万左右或更高
- 对应的 ETF 基金规模在 20 亿以上

测算的指数可大致分为**基础设施与地产、金融、科技、宽基、消费、医疗健康、制造、周期** 8 大产业/宽基板块，共计 **53** 个指数。

图表 11：部分指数一览

类别序号	产业板块/宽基	指数简称	指数代码 (如有全收益指数则使用全收益指数代码)
1	基础设施与地产	中证全指房地产指数	H20165.CSI
2	金融	中证全指证券公司指数	H20168.CSI
3	金融	中证银行指数	H20180.CSI
4	金融	沪深 300 非银行金融指数	H20035.CSI
5	金融	上证 180 金融股指数	H00018.CSI
6	科技	中证 5G 通信主题指数	931079.CSI
7	科技	中证电子 50 指数	931461.CSI
8	科技	中证电子指数	H20652.CSI
9	科技	中证光伏产业指数	H21151.CSI
10	科技	中证科技 50 指数	921380.CSI
11	科技	中证科技龙头指数	H21087.CSI
12	科技	中证全指半导体产品与设备指数	H20184.CSI
13	科技	中证全指通信设备指数	H21160.CSI
14	科技	中证生物科技主题指数	H20743.CSI
15	科技	国证半导体芯片指数	980017.SZ
16	科技	中华交易服务半导体芯片行业指数	980001.CSI
17	宽基	创业板指	399006.SZ
18	宽基	恒生互联网科技业指数	HSIII.HK
19	宽基	恒生中国企业指数	HSCE.HK
20	宽基	沪深 300 指数	H00300.CSI
21	宽基	恒生指数	HSI.HK
22	宽基	上证红利指数	H00015.CSI
23	宽基	上证科创板 50 成份指数	000688CNY01.SH
24	宽基	深证红利价格指数	399324.SZ

25	宽基	中证 1000 指数	H00852.CSI
26	宽基	中证 500 指数	H00905.CSI
27	宽基	中证港股通 50 指数	H20931.CSI
28	宽基	中证海外中国互联网 50 指数	H20533.CSI
29	宽基	中证红利指数	H00922.CSI
30	宽基	中证香港证券投资主题指数	H20709.CSI
31	宽基	上证 50 指数	H00016.CSI
32	宽基	上证 180 指数	H00010.CSI
33	宽基	创业板 50 指数	399673.SZ
34	宽基	深证 100 价格指数	399004.SZ
35	消费	中证酒指数	H20523.CSI
36	消费	中证细分食品饮料产业主题指数	H00815.CSI
37	消费	中证消费 50 指数	H21139.CSI
38	消费	中证主要消费指数	H00932.CSI
39	医疗健康	中证创新药产业指数	931152.CSI
40	医疗健康	中证生物医药指数	H20726.CSI
41	医疗健康	中证医疗指数	H20451.CSI
42	医疗健康	沪深 300 医药卫生指数	H00913.CSI
43	制造	中证国防指数	H20321.CSI
44	制造	中证军工龙头指数	H21066.CSI
45	制造	中证军工指数	H20229.CSI
46	制造	中证全指家用电器指数	H20697.CSI
47	制造	中证新能源汽车产业指数	H20997.CSI
48	制造	中证新能源汽车指数	H20522.CSI
49	制造	中证新能源指数	H20592.CSI
50	周期	中证钢铁指数	H20606.CSI
51	周期	中证煤炭指数	H20596.CSI
52	周期	中证农业主题指数	H00949.CSI
53	周期	中证申万有色金属指数	000819.SH

资料来源：同花顺 中信期货研究部



## 免责声明

除非另有说明，中信期货有限公司拥有本报告的版权和/或其他相关知识产权。未经中信期货有限公司事先书面许可，任何单位或个人不得以任何方式复制、转载、引用、刊登、发表、发行、修改、翻译此报告的全部或部分材料、内容。除非另有说明，本报告中使用的所有商标、服务标记及标记均为中信期货有限公司所有或经合法授权被许可使用的商标、服务标记及标记。未经中信期货有限公司或商标所有权人的书面许可，任何单位或个人不得使用该商标、服务标记及标记。

如果在任何国家或地区管辖范围内，本报告内容或其适用与任何政府机构、监管机构、自律组织或者清算机构的法律、规则或规定内容相抵触，或者中信期货有限公司未被授权在当地提供这种信息或服务，那么本报告的内容并不意图提供给这些地区的个人或组织，任何个人或组织也不得在当地查看或使用本报告。本报告所载的内容并非适用于所有国家或地区或者适用于所有人。

此报告所载的全部内容仅作参考之用。此报告的内容不构成对任何人的投资建议，且中信期货有限公司不会因接收人收到此报告而视其为客户。

尽管本报告中所包含的信息是我们于发布之时从我们认为可靠的渠道获得，但中信期货有限公司对于本报告所载的信息、观点以及数据的准确性、可靠性、时效性以及完整性不作任何明确或隐含的保证。因此任何人不得对本报告所载的信息、观点以及数据的准确性、可靠性、时效性及完整性产生任何依赖，且中信期货有限公司不对因使用此报告及所载材料而造成的损失承担任何责任。本报告不应取代个人的独立判断。本报告仅反映编写人的不同设想、见解及分析方法。本报告所载的观点并不代表中信期货有限公司或任何其附属或联营公司的立场。

此报告中所指的投资及服务可能不适合阁下。我们建议阁下如有任何疑问应咨询独立投资顾问。此报告不构成任何投资、法律、会计或税务建议，且不担保任何投资及策略适合阁下。此报告并不构成中信期货有限公司给予阁下的任何私人咨询建议。

中信期货有限公司

### 深圳总部

地址：深圳市福田区中心三路 8 号卓越时代广场（二期）北座 13 层 1301-1305、14 层

邮编：518048

电话：400-990-8826